本科毕业设计（论文）开题报告

专业：飞行器制造工程　　班级：05012201

学号	2022301606	姓名	陈雄杰	指导教师	宗立军
报告题目	面向多任务的机械臂智能运动规划方法研究				
题目来源（划√）	实践教学 ☐	科教融合 ☑	创新创业 ☐	产教融合 ☐	国际合作 ☐　本研贯通 ☐
论文类型（划√）	工程设计类☑	理论研究/论文类☐		其 他 ☐	
报告日期	2026 年 1 月 19 日		报告地点	航空楼 B716	

一、选题背景、意义及依据

在当前工业制造系统向个性化定制与快速响应市场变化的转型进程中，机器人技术的应用范式正经历深刻变革。其核心特征是从预先编程、固定节拍的刚性自动化，转向能够适应多品种、变批量、混线生产的柔性智能制造。在这一背景下，作为执行终端的工业机械臂被期望承担日益复杂与动态变化的作业任务，如不同型号工件的混合装配、个性化产品的柔性加工、以及产线动态重组后的即时作业切换。这对机械臂的运动控制系统提出了超越传统点位控制的高阶要求：系统不仅需要执行预定义的轨迹，更需要具备对“任务”本身的理解、分解与自主规划能力。当机器人型号、安装姿态或末端工具发生变化时，往往需要对 IK 模块进行耗时且专业的重新建模与参数整定，导致产线重构的周期和成本居高不下。因此，开发一种具备“构型自适应能力”的底层运动学求解方法，为实现真正的柔性化、智能化的多任务机械臂系统提供普适性核心基础，已成为当前机器人学与控制工程领域一个明确且急迫的研究需求。

传统逆运动学求解方法在“泛化能力”与“工程实用性”之间存在固有矛盾。解析法虽计算高效，但严重依赖于特定几何结构的可解性，无法适用于所有构型，尤其是冗余机械臂。以雅可比矩阵为基础的数值迭代法（如 Newton-Raphson 方法）虽然通用性较强，但其求解性能严重依赖于初始值，在奇异点附近表现不稳定，且计算效率随自由度增加而下降，难以保证在实时控制环中的鲁棒性。更重要的是，所有这些方法的模型参数（如 D-H 参数）均与机器人物理构型精确绑定，导致其本质上是一种“一机一码”的专用解决方案，无法实现跨平台的快速迁移。近年来，数据驱动的神经网络方法为解决该问题提供了新思路，但纯粹基于数据拟合的黑箱模型往往忽略了运动

学内在的几何与物理约束，可能导致输出结果违反关节限位或连杆间干涉等基本物理规律，在实际控制中存在安全隐患，且对训练数据的规模和质量要求极高。因此，核心挑战在于：如何构建一个“既具备从数据中学习跨构型通用映射能力，又能严格融入机器人运动学先验知识”的新型 IK 求解框架，从而在泛化性、精确性、实时性与安全性之间取得平衡。

本研究正是针对上述核心挑战，提出并探索一种 “基于可微正运动学约束的图神经网络逆运动学求解”新方法。其根本意义在于，尝试从底层运动学生成机制的层面进行创新，为机械臂的智能运动规划提供一个自适应、可重构的通用计算内核。在理论层面，推动机器人学核心问题与新兴人工智能范式进行深度融合，探索物理约束与数据驱动模型相结合的新路径，为构建下一代具有通用性与可解释性的机器人运动智能提供理论框架。在应用层面，致力于突破当前工业机器人柔性部署的关键瓶颈，通过提供一种自适应、可迁移的运动规划内核，显著降低多品种、变批量生产场景中的系统重构与调试成本，为智能制造、协作机器人等前沿方向的落地提供核心技术支撑。在行业层面，该研究有助于加速机器人从专用自动化设备向通用智能执行体的演进，对提升我国在高性能工业机器人核心算法领域的自主创新能力和技术储备具有积极意义。

二、国内外研究现状

围绕“构建具备构型自适应能力的通用逆运动学（IK）求解器”这一核心目标，现有的研究工作主要从图神经网络（GNN）的架构应用、模块化系统的控制范式以及机械臂的专用控制策略三个相互关联的层面展开探索。以下将分别对这三个方面的研究进展进行述评，并分析其与解决“如何将图神经网络的结构化学习优势与基于可微模型的严格运动学几何约束进行深度、系统性融合”这一关键难题的相关性及现存不足。

2.1 GNN 图神经网络与机器人运动学建模

图神经网络（GNN）因其对非欧几里得拓扑数据的强大建模能力，为机器人学的结构化建模提供了新颖框架，尤其体现在为控制策略学习提供与物理拓扑对应的图表示方法上。其核心思想是将机器人实体（如关节、连杆）抽象为图节点，将其间的连接与约束关系抽象为边，从而天然适配多关节机器人等具有图结构特征的场景。在机器人运动学领域，GNN 的应用正从物理状态预测向核心的运动学求解拓展。早期开创性工

作如 Wang 等人提出的 NerveNet，首次将 GNN 用于结构化策略学习，证明了其在不同拓扑结构机器人间进行策略迁移的潜力，启发了利用图结构实现跨构型泛化的思路[1]。Sanchez-Gonzalez 等人则利用 GNN 构建可学习的物理引擎，实现对多体系统动力学的预测与控制，为在数据驱动框架中融入物理规律提供了方法论基础[2]。

具体到逆运动学问题，研究重点在于利用 GNN 学习从末端位姿到关节空间的映射关系，以应对构型变化带来的挑战。Limoyo 等人提出的生成式图逆运动学方法，通过距离几何表示与图结构处理多解情况，展示 GNN 在捕捉机器人拓扑先验方面的优势[3]。Zhou 等人使用梯度神经网络求解时变逆运动学问题，则展现了 GNN 在动态控制任务中的潜力[4]。这些方法的核心进步在于，它们试图超越针对特定机器人的“白箱”解析模型，转而寻求一种能够从数据中学习跨构型运动学映射的“灰箱”模型。近年来，研究趋势进一步倾向于将 GNN 与可微分计算结合，例如 Ajay 等人探索将物理模拟器与基于对象的网络结合进行控制[5]，Pathak 等人研究通过模块化实现形态控制的泛化[6]，这些探索都在尝试为神经网络注入不同的物理归纳偏置。

然而，现有基于 GNN 的运动学建模研究，在解决“结构化学习与几何约束深度融合”这一核心难题上仍存在显著局限。首先，多数方法本质上仍是数据驱动的“黑箱”拟合，缺乏对运动学几何约束的结构化嵌入。虽然图结构引入了拓扑连接先验，但至关重要的、可微的正向运动学链式变换关系并未作为一个确定性、可微分的计算模块被强制整合进网络的前向传播路径中。这导致模型可能导致解的物理一致性无法得到根本保证。其次，在追求泛化能力时，牺牲了求解的实时性与确定性。现有 GNN 模型的推理速度、计算开销与经过高度优化的传统数值迭代法相比，尚未展现出决定性的效率优势，难以满足高实时性控制回路的严苛需求。这种“泛化性”与“工程实用性”之间的割裂，是当前方法迈向实际应用的主要障碍。当前的研究趋势正致力于打破这种割裂，核心方向是发展“可微物理约束下的高效图学习架构”。未来的研究不再满足于将 GNN 作为单纯的数据拟合器，而是将其重新设计为一个嵌入了可微运动学计算图的结构化推理框架。这要求在网络前向传播中，关节角预测必须经过一个可微的正运动学层“验证”，并将该过程产生的几何误差直接用于网络训练与推理优化，从而在机制上统一泛化能力与物理正确性，这构成了本研究探索新型融合范式的直接动因。

2.2 模块化机器人控制策略

模块化机器人系统因其可通过模块重组灵活适应多种任务，其核心控制挑战——如何为瞬息万变的构型生成有效策略——与本研究寻求“构型自适应”底层求解器的目标高度同构。该领域的研究为如何利用结构化表示实现系统层面的泛化提供了重要借鉴。传统基于预编程或集中优化的方法难以应对模块组合爆炸带来的状态空间复杂性。随着机器学习的发展，数据驱动、结构感知的控制方法成为主流。例如，Sartoretti 等人提出的分布式学习框架，通过为每个关节训练本地策略并利用通信进行协调，展示了在模块化 articulated mobile robots 上的良好泛化能力[7]。Chen 等人采用的硬件条件化策略，将机器人形态参数直接作为策略网络的输入，实现了跨不同构型机器人的控制策略迁移[8]。

图神经网络（GNN）在该领域展现出独特优势，因其能自然地将变化的模块连接关系表征为动态图，从而实现控制策略的参数共享与泛化。Whitman 等人提出的基于 GNN 的模块化控制策略是一个典型代表，该工作通过图消息传递机制在模块间协调动作，并利用模型强化学习进行训练，成功实现了对多种未见过的腿-轮复合构型的零样本控制[9]。这类工作表明，GNN 能够有效抽象并提取不同物理构型中共享的运动控制规律，为构建一个统一的、与具体形态解耦的高级控制器提供了可能。其他研究，如 Bjelonic 等人针对腿轮混合机器人的在线轨迹优化[10]，以及 Geilinger 等人“形态-控制”协同设计的优化框架[11]，虽未直接采用 GNN，但其核心思想——将机器人形态编码为可优化的参数并与控制策略协同考虑——与图结构表示的思想内在相通，共同推动了系统自适应能力的提升。

尽管模块化机器人控制研究在高层策略泛化上成果显著，但其对解决底层运动学泛化求解这一根本问题的贡献存在间接性和局限性。现有研究的主要不足在于：它们普遍聚焦于高层行为策略、步态生成或轨迹规划，其 GNN 或其他学习模型的输出通常是关节空间的目标轨迹、速度或力矩指令。这些研究在默认底层逆运动学问题已被妥善解决或可被简单模型近似的前提下，实现了“控制”层面的构型自适应。然而，当任务对末端执行器的轨迹精度、动态性能要求极高时，快速、精确且同样具备构型自适应能力的 IK 求解器是不可或缺的底层基石。当前模块化控制研究并未深入攻克这一基石性问题。因此，未来的智能模块化系统，需要其控制架构的每一层都具备与形态无关的泛化能力。本研究正是顺应这一趋势，致力于填补当前自适应控制链条中底层

的这一关键空白，为构建完全自适应的机器人系统提供核心基础。

2.3 基于 GNN 的机械臂运动学求解与控制

机械臂作为最经典且应用广泛的多关节机器人，其运动学求解与控制一直是机器人学研究的核心问题。近年来，图神经网络（GNN）因其在建模复杂结构关系方面的优势，被引入机械臂领域，主要探索了两种不同的技术路径：一是直接针对逆运动学（IK）映射关系进行建模与学习，例如，Alkhodary 和 Gur 利用注意力机制处理软体机械臂的逆运动学建模问题[12]，Li 等人则提出了结合解析步骤与神经网络的混合思路[13]；二是将 GNN 作为构建集成化控制策略的架构基础，例如将其用于实现跨拓扑的策略迁移[1]或多智能体控制的统一表示[14]。这些研究展示了 GNN 在应对机械臂运动学与控制问题上的多样性和潜力。

在专注于 IK 求解的研究中，学者们尝试用 GNN 及其变体直接建立从任务空间到关节空间的映射。例如，Alkhodary 和 Gur 提出的 Kinematics Transformer，利用注意力机制来处理软体机械臂的逆运动学建模问题，展示了高级神经网络架构在此类问题上的潜力[12]。Li 等人提出的 HybrIK 框架，虽然面向人体姿态估计，但其核心思路是解析几何步骤与神经网络学习相结合，为机械臂 IK 求解提供了一种有价值的混合范式借鉴，即不完全依赖黑箱网络，而是保留部分可解释、确定性的计算环节[13]。在集成控制方面，GNN 被用作构建结构化策略网络的骨架。例如，前文提及的 NerveNet 也适用于机械臂，其支持跨不同自由度机械臂的策略迁移[1]；Huang 等人提出的共享模块化策略，则通过 GNN 实现了对多种异构智能体的统一控制表征[14]。此外，在具体任务如抓取检测[15]、装配规划[16]中，GNN 也被用于处理场景中物体与机械臂之间的空间关系推理。

综观现有基于 GNN 的机械臂运动学与控制研究，其在推进“几何约束与学习融合”方面虽有多样化尝试，但系统性融合的深度仍有欠缺。大多数方法旨在用网络拟合整个 IK 函数，但缺乏将可微的正向运动学计算图作为网络中的一个不可绕过的、前向传播的必要组成部分。针对这些不足，纯粹的“黑箱”替代思路正在被更务实的“灰箱”或“白-灰-黑”混合架构思路所补充，即在网络中显式嵌入已知的、确定性的物理模型（如可微运动学），让神经网络专注于学习不确定的、复杂的映射部分。本研究提出的“可微正运动学约束的图神经网络”框架，正是顺应了第一点趋势，旨在通过创造性的结构设计，将严格的运动学几何作为神经网络的内在骨架而非外部监督，从而

在源头上确保泛化性与物理正确性的统一，并为最终在真实系统上的部署验证奠定坚实的算法基础。

三、课题研究目标、研究内容、研究方法及关键技术

3.1 研究目标

面向工业制造柔性化转型对机器人运动控制快速适配的迫切需求，针对传统逆运动学求解方法因与机械臂特定构型深度耦合而导致系统重构周期长、成本高的核心问题，本课题拟开展基于可微正运动学约束的图神经网络（GNN）逆运动学求解方法研究。旨在通过将机器人运动学链建模为图结构，并创新性地将可微正运动学计算作为强制性约束嵌入网络，提出一种兼具数据驱动学习能力与严格几何一致性的新型求解架构。实现该模型对训练数据外、具有不同自由度与连杆参数机械臂构型的泛化求解能力验证，从而为开发下一代适应性强、部署便捷的机器人智能运动控制底层模块提供了理论方法参考与实践基础。

3.2 研究内容

为实现构型自适应、物理可信的逆运动学求解，本研究将依次完成三项核心工作。首先，构建一种能统一描述不同构型机械臂的图表示方法与对应的神经网络架构，奠定模型泛化的基础。其次，在该架构中嵌入可微分的物理引擎并设计监督机制，确保网络输出严格遵循运动学规律。最后，在仿真环境中搭建完整的评估体系，从算法性能、任务完成到系统集成。具体研究内容如下：

3.2.1 机械臂的图结构化表征与几何感知型 GNN 构建

本部分的核心目标是建立一种与机器人构型无关的统一描述方法，并构建能够理解该描述的神经网络。首先，将机械臂建模为属性图结构，其中节点表示关节，包含类型与局部运动方向等属性；边表示连杆，编码其几何尺寸参数。该表示方法仅反映部件间的相对关系，而不依赖绝对坐标系，为模型适应不同构型提供基础。

在此基础上，设计一个具备几何感知能力的图神经网络（GNN）。该网络通过定制的消息传递机制，在特征传播中区分旋转与平移等几何变换，确保信息的空间一致性。该 GNN 作为求解器的前端，接收目标位姿和机械臂的图结构，输出关节空间的初步预测，供后续物理约束层进一步优化。

3.2.2 嵌入可微物理引擎的混合监督训练策略设计与实现

将运动学物理定律以可微分的形式嵌入神经网络，实现数据驱动与物理一致性的融合。核心是构建一个可微正运动学计算层，该层依据机械臂连杆参数和 GNN 预测的关节角度，通过链式矩阵乘法计算末端位姿，从而在网络内部形成闭合的几何约束。

为训练该模型，设计一种不依赖关节角真值的混合损失函数，主要包括末端位姿误差和关节运动范围约束两部分。通过可微物理层反向传播梯度，驱动网络在满足运动学规律和安全边界的前提下进行优化，实现高效、可靠的自我监督学习。

3.2.3 面向任务完成的仿真验证与系统化评估

将在仿真环境中建立多层次性能评估体系。首先对核心算法进行基础测试，验证其在精度、实时性、鲁棒性等方面是否满足作为运动学生成模块的基本要求，并与传统方法进行对比分析。

其次，以该求解器为内核封装可复用的基本动作单元，组合典型任务验证其在实际作业流程中的有效性与流畅性。最后，构建具备任务调度与执行功能的仿真控制系统，测试其在多任务、可重构场景中的整体性能，并初步探索模型在未见构型上的泛化能力，综合评价方法的实用潜力与技术优势。

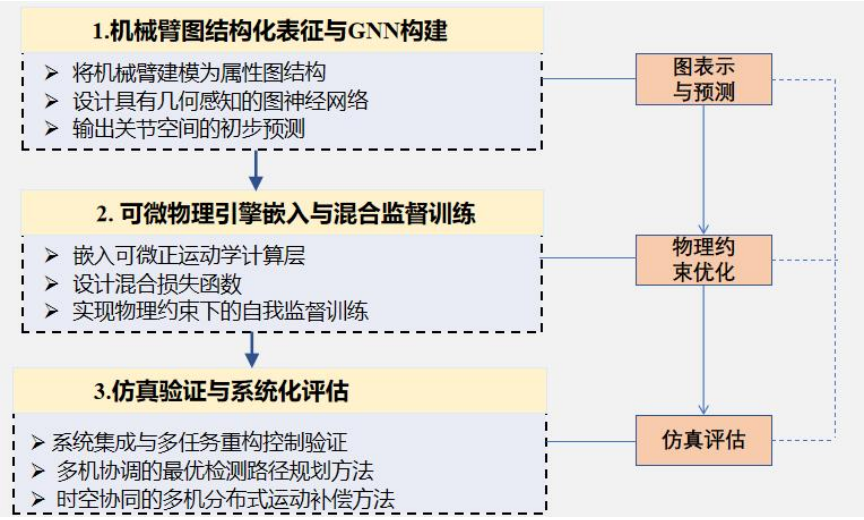

图 1：内容框架图

3.3 研究方法

针对“传统逆运动学方法缺乏构型自适应能力，而现有数据驱动方法又普遍缺乏严格的运动学物理一致性保证”这一核心矛盾，本研究旨在从结构化表征、约束化学习与系统性验证三个层面开展研究，以构建并验证一种新型的、物理可信的构型自适

应逆运动学求解器。主要技术路线如下：

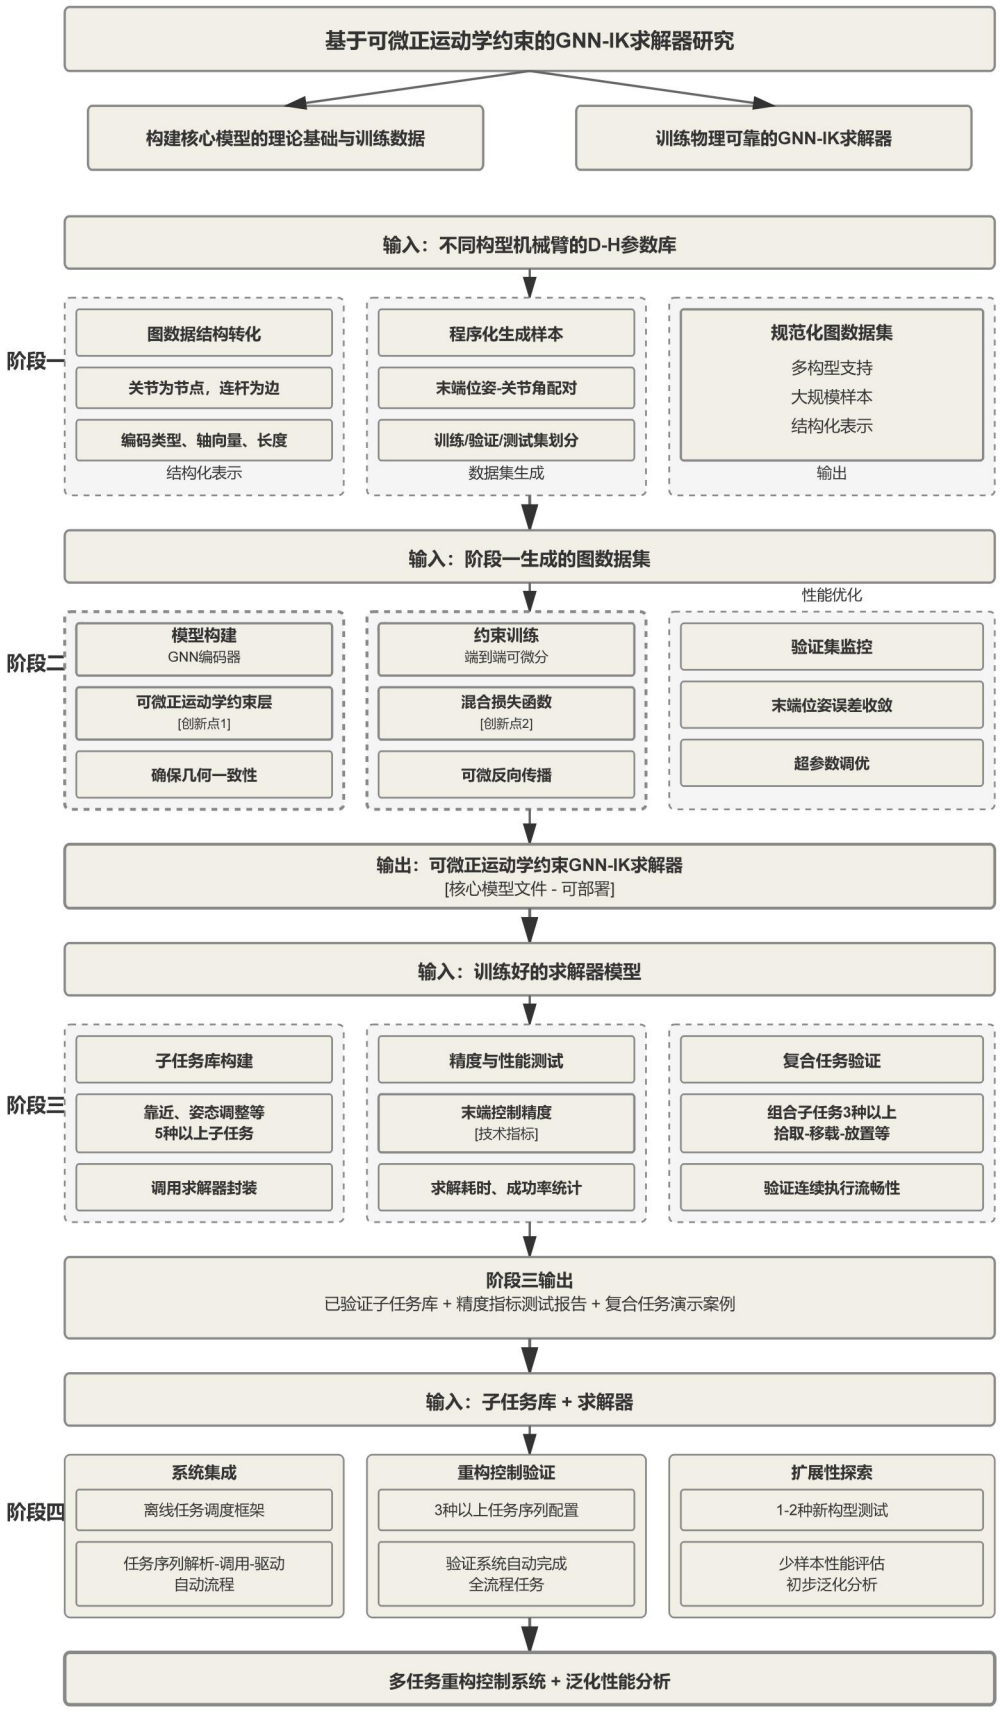

图 2：技术路线图

3.3.1 面向构型自适应的机械臂结构化表示与 GNN 架构设计

本部分研究如何使网络模型能够统一理解并处理不同构型机械的基础表征问题。研究主体将深入探索机械臂运动学链的规范化图表示方法。具体而言，将每个关节抽象为图节点，每个连杆抽象为边。关键在于设计一套与绝对世界坐标系解耦的局部特征编码体系：节点特征需编码关节类型（旋转/平移）及其局部旋转轴或平移方向向量；边特征则编码连接该连杆的规范 D-H 参数中的扭角与杆长。这种表示方法使模型感知的是机器人部件间的相对几何关系，而非绝对尺寸，为泛化奠定基础。

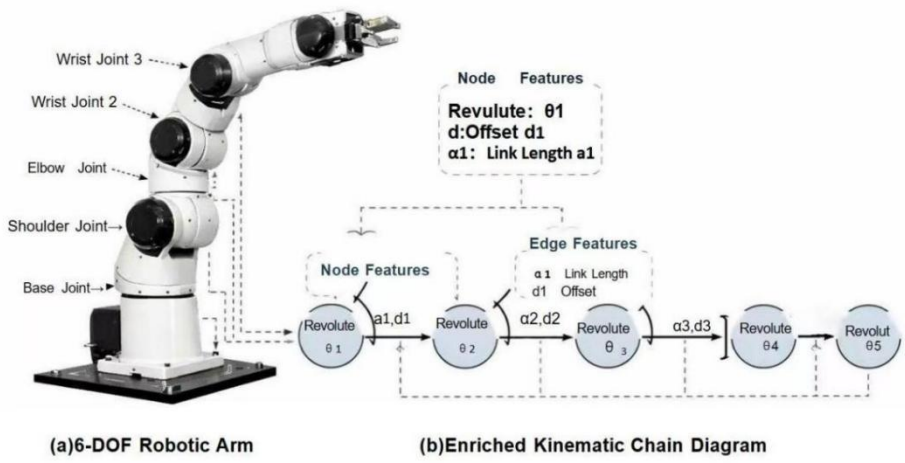

图 3：机械臂运动学链的图结构表示示意图

在此基础上，将设计一个具备几何感知能力的图神经网络（GNN）核心架构。该网络的消息传递与聚合函数需经过特别设计，以区分和处理三维空间中的旋转与平移变换，确保信息在图上传播时能够保持必要的几何等变或不变性质。该架构是整个研究的技术基石，其输出是机器人构型与目标位姿的联合函数，为下游的几何约束层提供初始的关节空间预测。

3.3.2 融合可微几何约束的混合训练与优化策略

针对如何在数据驱动的学习框架中硬性嵌入运动学定律，确保输出解的物理正确性这一关键挑战，将构建一个可微正运动学计算层作为网络的强制约束模块。该层以前述 GNN 输出的关节角预测为输入，依据机械臂的图结构信息（连杆参数），严格按运动学链顺序执行从基座标到末端的所有可微刚体变换矩阵连乘，最终计算出预测的末端位姿（位置与姿态）。

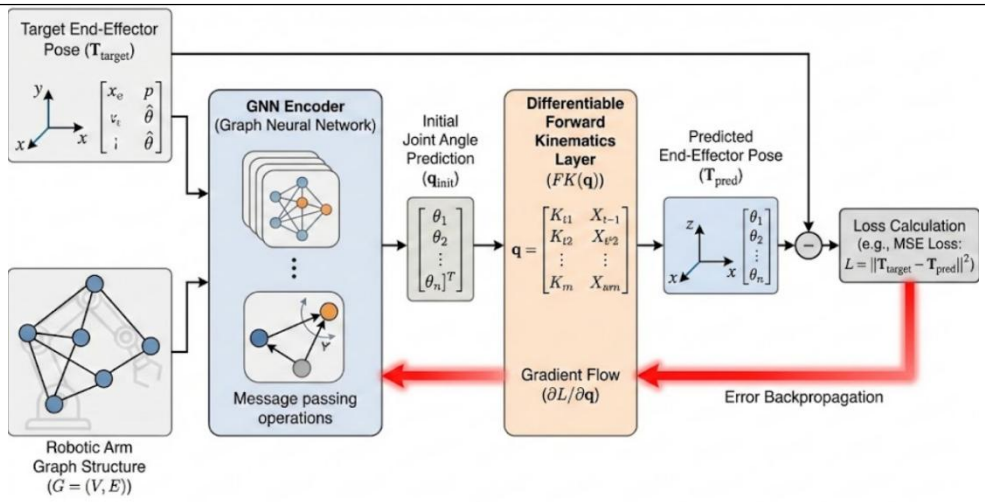

图 4：可微正运动学约束训练框架示意图

训练策略的核心是设计一种以末端位姿误差为主导的混合损失函数。该损失函数($\mathcal{L}$)主要由以下部分构成：

（1）末端位姿误差损失 ($\mathcal{L}_{pose}$)：此部分强制网络预测的关节角必须通过正运动学映射后，尽可能接近目标位姿。它可分解为位置误差和姿态误差：

$$\mathcal{L}_{pose} = \lambda_{pos} \cdot \|\mathbf{p}_{pred} - \mathbf{p}_{target}\|_2^2 + \lambda_{rot} \cdot \|\mathbf{q}_{pred} - \mathbf{q}_{target}\|_2^2,$$

其中，($\mathbf{p}_{pred}, \mathbf{q}_{pred}$)为网络预测关节角经可微正运动学层计算得到的末端位置与姿态，($\mathbf{p}_{target}, \mathbf{q}_{target}$)为目标末端位姿。($\lambda_{pos}$)和($\lambda_{rot}$)为平衡两项权重的超参数。

（2）关节限位约束损失($\mathcal{L}_{limit}$)：此部分作为正则项，引导网络输出符合机械臂物理运动范围的解，避免无效或危险的关节角：

$$\mathcal{L}_{limit} = \sum_{i=1}^{n} \max(0, \theta_i - \theta_i^{\max})^2 + \max(0, \theta_i^{\min} - \theta_i)^2,$$

其中，(θ_i)为网络对第 i 个关节的预测角度，($\theta_i^{\min}$)和($\theta_i^{\max}$) 为该关节的运动下限和上限。当预测值超出界限时，此项会产生惩罚。

总损失函数：最终用于训练网络的总损失为上述各项的加权和：

$$\mathcal{L}_{total} = \mathcal{L}_{pose} + \lambda_{limit} \cdot \mathcal{L}_{limit},$$

其中，(λ_{limit})是控制关节限位约束强度的超参数。该损失函数通过可微正运动学层进行反向传播，直接优化 GNN 的参数，使其学会在严格的几何物理约束下进行推理。

主损失函数直接计算预测末端位姿与目标位姿之间的位置误差，通过自动微分，该几何误差将直接、透明地通过可微正运动学层反向传播至 GNN，从而驱动网络学习到严格满足运动学闭环的映射关系。此外，将引入针对关节运动范围与连杆碰撞的正则

化约束项作为辅助损失，以引导网络生成更符合物理现实的、平滑的关节角解，从而在无需精确关节角标注数据的情况下，实现高效、稳定的自我监督训练。

3.3.3 基于仿真与任务导向的模型评估与泛化分析

本部分旨在紧扣毕业设计任务书的核心要求，建立一套从算法基础到任务功能，再到系统集成的层级化验证体系，以确保研究成果切实达到既定技术指标，并对所提方法的扩展潜力进行初步探索。研究主体将设计并实施三个层次的评估实验：

首先，进行核心算法模块的精度与基础性能验证。在仿真环境中，将本研究提出的“可微正运动学约束 GNN-IK 求解器”作为统一的底层运动学生成模块进行测试。重点评估其在执行各类子任务（如点到点运动、姿态调整、推移）时的末端控制精度，确保其达到任务书要求的“单个子任务控制精度小于 1mm”的核心指标。同时，将记录其求解耗时、成功率和数值稳定性，并与任务中拟替换的传统 IK 求解器进行对比，以验证其作为可靠底层模块的可行性。

其次，一阶段验证的 GNN-IK 求解器为统一运动学生成内核，设计并封装一组可复用的基本动作，形成初步的子任务库。每个子任务的轨迹点都将通过该求解器实时计算得到关节空间解。通过在仿真中组合这些原语来完成至少 3 种不同的复合任务（如“靠近-调整姿态-推移”等），验证任务分解策略的有效性以及子任务独立控制与连续执行的流畅性，从而满足任务分解与重构的功能性指标。

最后，实施系统级集成与重构控制验证。研究将在仿真平台中搭建一个具备任务调度功能的简易控制框架。该框架的底层将调用本研究实现的 GNN-IK 求解器与基于它构建的子任务库。通过离线配置不同的任务序列（不少于 3 种），系统将自动完成从任务解析、子任务调度到调用统一求解器生成关节轨迹的完整流程。在整个验证过程中，跨构型泛化能力将作为一项重要的探索性分析与潜在优势进行考察。我们将在核心算法验证阶段，尝试将训练好的模型在少数 1-2 种未经专门训练、但结构相似的仿真机械臂上进行测试，初步分析其性能变化趋势，为该方法未来潜在的通用性提供参考依据。

3.4 关键技术

本课题将在主流深度学习框架 PyTorch 下构建模型，并在物理仿真环境中进行验证。在诸多技术环节中，可微分正运动学层与图神经网络的结构化深度融合是确保本

研究从方法创新走向可行实现的最为核心与关键的技术。

其关键在于它直接决定了本课题能否在“构型自适应”与“物理一致性”之间取得实质性突破。 如研究背景与现状分析所述，现有基于 GNN 的逆运动学方法，其核心瓶颈在于未能将刚体运动的几何定律作为不可违背的硬性约束内化于学习过程。若仅将 GNN 视为一个黑箱函数逼近器，即使其输入了图结构，其输出仍可能违反运动学基本原理，导致解不可信。因此，设计一个与 GNN 前向传播无缝集成的可微分正运动学计算层，并非一个可选的改进，而是构建一个真正可靠、可利用的“物理智能”求解器的架构性前提。该层将成为连接数据驱动表示 GNN 输出的关节角与末端位姿的唯一且可微的桥梁，迫使所有网络预测都必须经过严格运动学变换的“检验”才能产生最终输出，从而在机制上保障了解的物理正确性。

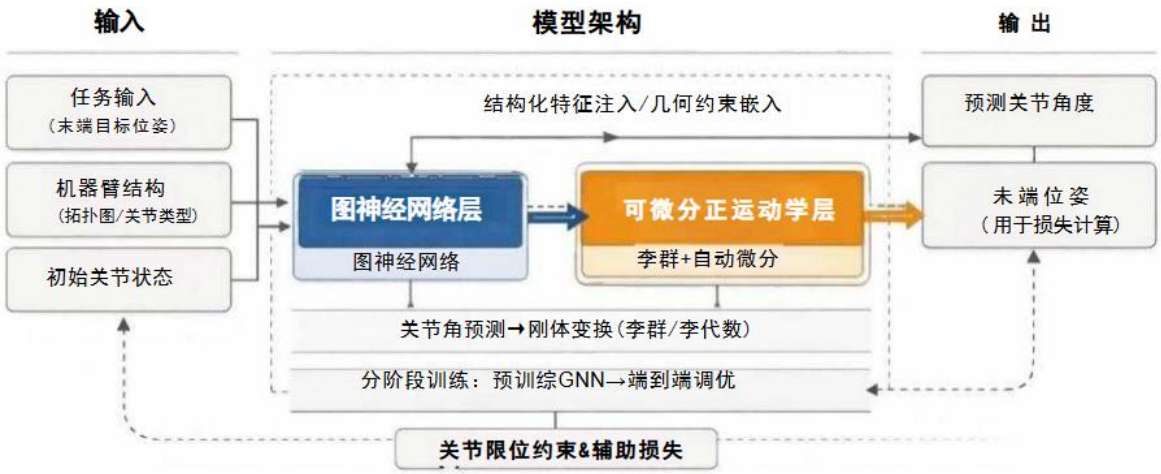

图 5：可微分运动学引导的图网络

本课题的技术路线将紧密围绕攻克此关键技术展开。具体而言，将首先基于李群与李代数理论实现一个可微分刚体变换库；继而设计一种模块化网络架构，使 GNN 模块与正运动学层通过清晰的接口耦合；最终采用分阶段训练策略，先预训练 GNN 的编码能力，再引入可微层进行端到端精细调优，以确保整个系统稳定、高效地学习到满足物理约束的泛化逆运动学映射。

四、论文所遇到的困难和问题、拟采取的解决措施及预期达到的目标

4.1 拟解决的关键问题与应对思路

4.1.1 物理约束深度嵌入的架构设计挑战

本研究所采用的几何感知图神经网络（GNN）模型，因其需处理高维几何特征与复杂的拓扑关系，在训练阶段通常面临较高的计算复杂度与显存占用。具体而言，模型的图结构消息传递、高维空间中的旋转与平移等变操作、以及伴随可微物理层的大规模梯度计算，均对硬件算力（特别是 GPU 的并行计算能力与显存容量）提出了较高要求。在有限的本地实验条件下，这可能成为制约模型快速迭代、大规模数据训练以及超参数调优的实际瓶颈。

应对策略：针对上述资源约束，拟从算法与工程两个层面进行优化。在算法层面，将着重设计更轻量化的网络架构，例如通过稀疏化消息传递、采用高效的注意力机制来减少计算复杂度。同时，将研究分阶段与课程学习的训练策略，先在小规模数据集或简化任务上预训练模型主干，再逐步扩展到完整任务，以提升训练效率与稳定性。在工程实现层面，将充分利用现有开源深度学习框架的混合精度训练、梯度检查点等显存优化技术，并规划利用云端计算资源进行大规模实验，以在可获取的资源范围内最大限度地保障研究的可行性与实验进度。

4.1.2 训练过程的收敛稳定性问题

引入可微物理约束后，训练动态将变得更加复杂。模型需要同时学习几何映射与满足约束，在训练初期，GNN 输出的随机预测会导致正运动学层产生巨大的末端位姿误差，可能引发梯度爆炸或消失，从而导致训练难以收敛或收敛至性能不佳的局部最优点。

应对策略：为提升训练稳定性，计划采用 “预训练-微调”与课程学习相结合的分阶段策略。首先，在预训练阶段，使用一个简化的辅助任务，直接预测已知数据集中样本的关节角对 GNN 编码器进行初始化，使其快速学习到机器人结构与关节空间的基本关联，避免从完全随机状态开始接触物理约束。随后，在主训练阶段，引入完整的可微正运动学层与末端位姿损失，并采用课程学习策略，从易于求解的、靠近训练数据分布中心的末端位姿样本开始训练，逐步过渡到更具挑战性的、边界或奇异点附近的位姿样本。此外，将实施梯度裁剪和监控损失曲面，以动态稳定训练过程。

4.2 预期达到的研究目标

通过对上述研究内容的探索与实践，期望在本毕业设计周期内，围绕任务书设定的三个核心研究方向，实现以下层次递进的阶段性目标：

探索并验证机械臂任务分解与子任务库构建的可行性。核心目标是设计一套任务分解策略，将任务书中指定的多种复杂操作解析为一系列基本的、可执行的运动子任务，并尝试构建一个包含不少于 5 种子任务单元的初步子任务库。这一阶段旨在验证所述方法在逻辑层面支持复杂任务分解的能力。

其次，实现基于新型求解器的子任务运动规划与控制。在构建子任务库的基础上，重点将本研究提出的“可微正运动学约束 GNN-IK 求解器”作为统一的底层运动生成器进行集成与测试。目标是对库中的每个子任务进行运动规划与控制实现，通过仿真实验努力使单一子任务的末端精度达到要求，并验证该求解器作为准确、可靠底层控制模块的潜力。

最终，初步完成多任务离线重构控制的系统演示，实现针对不少于 3 种不同复合任务序列的离线编程与自动执行。旨在将所开发的求解器作为底层模块，尝试驱动机械臂完成若干由任务书规定的、具有代表性的子任务与复合任务。在过程中综合考察并分析该求解器在连续运动规划中的稳定性、精度以及整个系统的协调性。

五、论文进度安排

2026.01.07 - 01.31：文献调研

2026.02.01 - 02.28：核心算法开发环境与基础模块实现。

2026.03.01 - 03.25：GNN-IK 模型构建、训练与初步验证。

2026.03.26 - 04.16：子任务库构建与单任务精度优化。

2026.04.17 - 05.10：多任务集成仿真与系统验证。

2026.05.11 - 06.10：毕业论文撰写、修改与答辩准备。

六、参考文献

[1] Wang T, Liao R, Ba J, et al. Nervenet: Learning structured policy with graph neural networks[C]//International conference on learning representations. 2018.

[2] Sanchez-Gonzalez A, Heess N, Springenberg J T, et al. Graph networks as learnable physics engines for inference and control[C]//International conference on machine learning. PMLR, 2018: 4470-4479.

[3] Limoyo O, Marić F, Giamou M, et al. Generative Graphical Inverse Kinematics[J]. Ieee transactions on robotics, 2024.

[4] Zhou Y, Liu K, Li C, et al. A Gradient Neural Network for online Solving the Time-varying Inverse Kinematics Problem of Four-wheel Mobile Robotic Arm[C]//2021 IEEE 10th Data Driven Control and Learning Systems Conference (DDCLS). IEEE, 2021: 391-396.

[5] Ajay A, Bauza M, Wu J, et al. Combining physical simulators and object-based networks for control[C]//2019 International Conference on Robotics and Automation (ICRA). IEEE, 2019: 3217-3223.

[6] Pathak D, Lu C, Darrell T, et al. Learning to control self-assembling morphologies: a study of generalization via modularity[J]. Advances in Neural Information Processing Systems, 2019, 32.

[7] Sartoretti G, Paivine W, Shi Y, et al. Distributed learning of decentralized control policies for articulated mobile robots[J]. IEEE Transactions on Robotics, 2019, 35(5): 1109-1122.

[8] Chen T, Murali A, Gupta A. Hardware conditioned policies for multi-robot transfer learning[J]. Advances in Neural Information Processing Systems, 2018, 31.

[9] Whitman J, Travers M, Choset H. Learning modular robot control policies[J]. IEEE Transactions on Robotics, 2023, 39(5): 4095-4113.

[10] Bjelonic M, Sankar P K, Bellicoso C D, et al. Rolling in the deep–hybrid locomotion for wheeled-legged robots using online trajectory optimization[J]. IEEE Robotics and Automation Letters, 2020, 5(2): 3626-3633.

[11] Bjelonic M, Sankar P K, Bellicoso C D, et al. Rolling in the deep–hybrid locomotion for wheeled-legged robots using online trajectory optimization[J]. IEEE Robotics and Automation Letters, 2020, 5(2): 3626-3633.

[12] Geilinger M, Poranne R, Desai R, et al. Skaterbots: Optimization-based design and motion synthesis for robotic creatures with legs and wheels[J]. ACM Transactions on Graphics (TOG), 2018, 37(4): 1-12.

[13] Alkhodary A, Gur B. Kinematics transformer: Solving the inverse modeling problem of soft robots using transformers[J]. arXiv preprint arXiv:2211.06643, 2022.

[14] Li J, Xu C, Chen Z, et al. Hybrik: A hybrid analytical-neural inverse kinematics solution for 3d human pose and shape estimation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 3383-3393.

[15] Huang W, Mordatch I, Pathak D. One policy to control them all: Shared modular policies for agent-agnostic control[C]//International Conference on Machine Learning. PMLR, 2020: 4455-4464.

[16] Jimenez-Moreno R, Fonseca A R, Ramirez J L. Object gripping algorithm for robotic assistance by means of deep learning[J]. International Journal of Electrical and Computer Engineering (IJECE), 2020, 10(6): 6292-6299.

[17] Liu Y, Cong M, Dong H, et al. Human skill integrated motion planning of assembly manipulation for 6R industrial robot[J]. Industrial Robot: the international journal of robotics research and application, 2019, 46(1): 171-180.

[18] Scarselli F, Gori M, Tsoi A C, et al. The graph neural network model[J]. IEEE transactions on neural networks, 2008, 20(1): 61-80.

[19] Wu Z, Pan S, Chen F, et al. A comprehensive survey on graph neural networks[J]. IEEE transactions on neural networks and learning systems, 2020, 32(1): 4-24.

指导教师意见：

同意开题。

签名（手签）

2016年 1 月 20日

开题评议小组成员：

开题评议小组意见：（包括对论文的选题、难度、进度、工作量、论文形式意见）：

1. 论文选题: ☐ 有理论意义；☐ 有实用价值；☑ 有理论意义与实用价值；

☐ 意义不大。

2. 论文的难度: ☐ 偏高；☑ 适当；☐ 偏低。

3. 论文的工作量: ☐ 偏大；☑ 适当；☐ 偏小，

4. 进度: ☑ 可行；☐ 不可行；

5. 学生开题报告中反映出的综合能力和表达能力: ☑ 好； ☐ 较好；一般；☐ 较差，

6. 论文形式意见：☑ 可行；☐ 不可行；

7. 对论文开题报告的总体评价: ☑ 好；☐ 较好；☐ 一般；☐ 较差，

（在相应的方块内作记号“√”）

评 议 结 论	是否同意论文开题报告：☑ 同意；☐ 需重做 （在相应的方块内作记号“√”） 评议小组组长签名（手签）：2016年 1 月 23 日